

CERTIFICATION OF TRANSLATION ACCURACY

Document Type: Article
Source Language: Portuguese
Target Language: English
Number of pages: 01

 **American Translators Association**
273295 *The Voice of Interpreters and Translators*

Roxo Translations (“we” or “our”) is Corporate Member 273295 of the American Translators Association (ATA), and is a professional translation agency. We are not related in any way to the client for whom this translation was completed. We hereby certify that the document described above has been translated by our experienced and qualified professional contract translator, fluent in and competent to translate from the source to the target languages. In our best judgment, the translated text accurately reflects the content, meaning and style of the original text, and constitutes in every respect a correct, true and complete translation of the original document.

Our certification relates to the correctness of the translation only. We do not guarantee that the original document is genuine, nor do we guarantee that the statements contained in the original document are true. Furthermore, we assume no liability for the way in which the translation is used by our client or any third party, including end-users of the translation.

A copy of the translation is attached to this certification.

Sincerely,



Daniela Lopes
Roxo Translations
Dated: April 14, 2022
State of Florida



County of Orange

A notary public or other officer completing this certificate verifies only the identity of the individual who signed the document to which this certificate is attached, and not the truthfulness, accuracy, or validity of that document.

Subscribed and sworn to (or affirmed) before me on April 14, 2022, by Daniela Lopes proved to me on the basis of satisfactory evidence to be the person who appeared before me.



Notary Public Signature



Infrastructure for AI: What do I need to understand?

Ricardo Nunes Ferreira

Did you know that the term "Artificial Intelligence" (AI) first appeared in 1956 in the title of the "Dartmouth Summer Research Project on Artificial Intelligence" event? Did you know that in 1959 Arthur Lee Samuel (while employed by IBM in Poughkeepsie, New York) coined the term machine learning, inaugurating a subfield of AI whose purpose would be to provide computers with the ability to learn without being programmed? Here comes the question: If AI emerged in the 1950s, why has it only now received due visibility?

For decades, the dominant approach in the field of AI was based on computer logic programs, marginalizing the machine learning-based view. Many researchers in the field attribute this to the lack of knowledge on the part of most scientists at that time, and some historians attribute it, in turn, to the limitation of the technology available at the time, which was unable to process the large amounts of data and mathematical calculations of the many existing academic studies. As the decades passed, the increasing amount of data to be worked on using traditional statistical models made them unfeasible for programmers to use. A new approach was then needed, that is, a new statistical model that could, from a large volume of data, correlate samples delivering adequate predictions for various use cases, thus giving rise to a new subfield of machine learning called deep learning.

In the 1980s a small group of researchers formed by Yann LeCun, Geoffrey Hinton and Yoshua

Bengio decided to insist on advancing studies related to deep learning, using a technique called Artificial Neural Networks. Neural networks are computational models inspired by the central nervous system of an animal (in particular the brain) that are capable of machine learning as well as pattern recognition. Artificial neural networks are usually presented as systems of interconnected neurons that can compute input values, simulating the behavior of biological neural networks. For example, a neural network for handwriting recognition is defined by a set of input neurons that can be activated by the pixels of an input image. The data acquired by this activation of neurons is then weighted, transformed by a function determined by the network developer, and passed on to other neurons. This process is repeated until finally an output neuron is activated; this determines that the character has been read.

Still thinking about this example, imagine how many times that same neural net would need to be run and trained before it could determine all the pixels in a single image? Imagine 30 million images and so on. This is the knowledge base to understand the real reason for the need of an adequate infrastructure to run, train, and infer the models within an artificial intelligence development conveyor belt.

The need for data governance and massive processing has made AI more visible only "recently," as technologies such as big data

and GPU (Graphics Processing Unit), were only discovered, improved, and commercially available to society nearly two decades ago. Having clarified the reason for the "recent visibility" of AI, it is also necessary to clarify why this technological dependence exists. Within an AI development pipeline there are three major stages: data (data governance / big data), training (model coding / training), and inference (model inference). Each of these stages, under the technological aspect, demands requirements that need to be addressed for its full operation, such as the need for servers that use GPU to train the neural networks.

But why should I use a GPU server to train my deep learning model? The answer is simple: training a deep learning algorithm using only the CPU (Central Processing Unit) can take days. With processing done on GPU-based servers the same task can take hours, minutes, or even seconds. The architecture of CPUs is composed of few cores with cache memory that



can handle a minimum limit of threads at a time, although they do so quickly. In contrast, GPUs have an architecture consisting of thousands of cores that can handle thousands of threads simultaneously. GPUs, typically used for rendering images and videos, can also be used to help solve computationally intensive mathematical problems using parallel processing. NVIDIA, for example, developed its GPUs and the CUDA programming language (Compute Unified Device Architecture), allowing its graphics processors to be used to

process data, making it possible to write code that interacts directly with the GPU.

It is important to remember that using the GPU will not be effective for all use cases, that is, applications designed for serial processing (where one task is completed at a time and all tasks are executed by the processor in a sequence) are less effective and perform worse when run on a GPU, rather than a CPU.

In the same way that we described the requirements of the training stage, it is necessary to analyze the technical characteristics required in the other stages of the AI conveyor belt. Remember that a suitable architecture is one that meets the specifications and requirements of all the areas involved in the project. Think, ask, research, and develop new experiences. Good luck!

To learn more

https://en.wikipedia.org/wiki/Arthur_Samuel
<https://pt.wikipedia.org/wiki/Nvidia>
https://pt.wikipedia.org/wiki/Aprendizagem_profunda
https://pt.wikipedia.org/wiki/Yann_LeCun
https://pt.wikipedia.org/wiki/Unidade_de_processamento_gr%C3%A1fico
https://pt.wikipedia.org/wiki/Geoffrey_Hinton
https://en.wikipedia.org/wiki/Dartmouth_workshop
https://pt.wikipedia.org/wiki/Yoshua_Bengio
<https://pt.wikipedia.org/wiki/CUDA>



Ricardo Nunes Ferreira is an IT architect at IBM Brazil with over 20 years of experience in Information Technology (IT). He holds an undergraduate degree in Computer Science by Unicsul with several certifications in IT. Graduate degree in Strategic Business Management by FIAP. He currently leads complex outsourcing solutions at IBM. For more information, send an email to ricardon@br.ibm.com

All information and opinions presented in this article are the sole responsibility of the author, and do not necessarily reflect the opinion or position of his employer



Infraestrutura para AI: O que preciso entender?

Ricardo Nunes Ferreira

Você sabia que o termo “Inteligência Artificial” (IA) apareceu pela primeira vez, em 1956, no título do evento “*Dartmouth Summer Research Project on Artificial Intelligence*”? Você sabia que, em 1959, Arthur Lee Samuel (enquanto funcionário da IBM em Poughkeepsie, New York) cunhou o termo *machine learning* inaugurando um subcampo da IA cuja finalidade seria prover os computadores da capacidade de aprender sem serem programados? Aí vem a pergunta: se a IA surgiu na década de 1950, por que somente agora recebeu a devida visibilidade?

Por décadas, a abordagem dominante no campo da IA foi baseada em programas lógicos de computação, marginalizando a visão baseada no aprendizado de máquina (*machine learning*). Muitos pesquisadores da área atribuem a ocorrência desse fato à falta de conhecimento por parte da maioria dos cientistas daquela época, e alguns historiadores, por sua vez, à limitação da tecnologia disponível na época, incapaz de processar a grande quantidade de dados e cálculos matemáticos dos muitos estudos acadêmicos já existentes. Na medida em que as décadas se passaram, o aumento da quantidade de dados a serem trabalhados utilizando os modelos estatísticos tradicionais tornou-as inviáveis para o uso dos programadores. Era necessária então uma nova abordagem, ou seja, um novo modelo estatístico que conseguisse, a partir de um grande volume de dados, correlacionar amostras entregando previsões adequadas para os diversos casos de uso, dando origem assim a um novo subcampo do *machine learning* chamado aprendizado profundo ou *deep learning*.

Na década de 1980 um grupo restrito de pesquisadores formado por Yann LeCun, Geoffrey Hinton e Yoshua Bengio resolveu insistir no avanço dos estudos relacionados ao *deep learning*, utilizando uma técnica chamada de Redes Neurais Artificiais. As redes neurais (*neural networks*), são modelos computacionais inspirados pelo sistema nervoso central de um animal (em particular o cérebro) que são capazes de realizar o aprendizado de máquina bem como o reconhecimento de padrões. As redes neurais artificiais geralmente são apresentadas como sistemas de neurônios interconectados, que podem computar valores de entradas, simulando o comportamento de redes neurais biológicas. Por exemplo, uma rede neural para o reconhecimento de escrita manual é definida por um conjunto de neurônios de entrada que podem ser ativados pelos *pixels* de uma imagem de entrada. Os dados adquiridos por essa ativação dos neurônios são então ponderados, transformados por uma função determinada pelo desenvolvedor da rede e repassados a outros neurônios. Este processo é repetido até que, finalmente, um neurônio de saída seja ativado; isso determina que o caractere foi lido.

Ainda pensando nesse exemplo, imagine quantas vezes essa mesma rede neural precisaria ser executada e treinada até que ela determinasse todos os *pixels* de uma única imagem? Imagine em 30 milhões de imagens e assim sucessivamente. Essa é a base do conhecimento para entender o real motivo da necessidade de uma infraestrutura adequada para executar, treinar e fazer a inferência dos modelos dentro de uma esteira de desenvolvimento de inteligência artificial.

A necessidade da governança de dados e do processamento maciço fez com que a IA só tivesse maior visibilidade “recentemente”, pois tecnologias como *big*

data e GPU (*Graphics Processing Unit*, ou Unidade de Processamento Gráfico), só foram descobertas, aprimoradas e comercialmente disponibilizadas para a sociedade há praticamente duas décadas. Esclarecido o motivo da “recente visibilidade” da IA, é necessário também esclarecer o porquê dessa dependência tecnológica. Dentro de uma esteira de desenvolvimento de IA existem três grandes etapas: *data* (governança dos dados / *big data*), *training* (codificação / treinamento dos modelos) e *inference* (inferência dos modelos). Cada uma dessas etapas, sob o aspecto tecnológico, exige requisitos que precisam ser endereçados para o seu pleno funcionamento, como por exemplo, a necessidade de servidores que utilizam GPU para o treinamento das redes neurais.

Mas por que deve-se usar um servidor com GPU para treinar meu modelo de *deep learning*? A resposta é simples: treinar um algoritmo de *deep learning* utilizando somente a CPU (*Central Processing Unit*) pode levar dias. Com o processamento feito em servidores baseados em GPU a mesma tarefa pode levar horas, minutos ou até segundos. A arquitetura das CPUs é composta de

poucas *cores* com memória de cache que podem tratar um limite mínimo de *threads* por vez, embora façam isso de forma rápida. Em contraste, as GPUs possuem uma arquitetura composta de milhares de *cores* que conseguem tratar milhares de *threads* simultaneamente.

As GPUs, tipicamente utilizadas para renderização de imagens e vídeos, podem também ser utilizadas para ajudar a resolver problemas matemáticos que requerem uma computação intensiva com o uso de processamento em paralelo. A NVIDIA, por exemplo, desenvolveu suas GPUs e a linguagem de programação CUDA (*Compute Unified*

Device Architecture), permitindo que os seus processadores gráficos sejam usados para processar dados, sendo possível escrever um código que interaja diretamente com a GPU.

É importante lembrar que o uso da GPU não será efetivo para todos os casos de uso, ou seja, aplicativos desenvolvidos para processamento serial (onde uma tarefa é concluída por vez e todas as tarefas são executadas pelo processador em uma sequência) é menos efetivo e performático quando executado em uma GPU, ao invés de uma CPU.

Da mesma forma que descrevemos os requisitos da etapa de treinamento, é necessário analisar as características técnicas exigidas nas demais etapas da esteira de IA. Lembre-se que uma arquitetura adequada é aquela que atende as especificações e requerimentos de todas as áreas envolvidas no projeto. Pense, pergunte, pesquise e desenvolva novas experiências. Boa sorte!



Para saber mais

https://en.wikipedia.org/wiki/Arthur_Samuel
<https://pt.wikipedia.org/wiki/Nvidia>
https://pt.wikipedia.org/wiki/Aprendizagem_profunda
https://pt.wikipedia.org/wiki/Yann_LeCun
https://pt.wikipedia.org/wiki/Unidade_de_processamento_gr%C3%A1fica
https://pt.wikipedia.org/wiki/Geoffrey_Hinton
https://en.wikipedia.org/wiki/Dartmouth_workshop
https://pt.wikipedia.org/wiki/Yoshua_Bengio
<https://pt.wikipedia.org/wiki/CUDA>



Ricardo Nunes Ferreira é arquiteto de TI na IBM Brasil com mais de 20 anos de experiência em Tecnologia da Informação (TI).

É formado em Ciências da Computação pela Unicsul com diversas certificações em TI.

Pós-graduado em Gestão Estratégica de Negócios pela FIAP.

Atualmente, lidera soluções complexas de outsourcing da IBM.

Para maiores informações, envie e-mail para ricardon@br.ibm.com.

Todas as informações e opiniões apresentadas neste artigo são de inteira responsabilidade do seu autor, e não refletem, necessariamente, a opinião ou posicionamento do seu empregador